

Filas bayesianas del Cholesky modificado con prior climatológico: formulación y calibración de α

Nota de trabajo

15 de septiembre de 2026

1 La fila como regresión bayesiana

En el Cholesky modificado, el componente i se regresa sobre sus predecesores $P(i)$ usando las N anomalías del ensamble de pronóstico. Con $\mathbf{y} \in \mathbb{R}^N$ las anomalías de i y $\mathbf{X} \in \mathbb{R}^{N \times p}$ las de sus p predecesores,

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \quad \boldsymbol{\varepsilon} \sim \mathcal{N}(0, \sigma^2 \mathbf{I}). \quad (1)$$

La fila i de $\mathbf{L}$ es $-\boldsymbol{\beta}^\top$ en las columnas $P(i)$ y $\mathbf{D}_{ii} = 1/\sigma^2$, y $\widehat{\mathbf{B}}^{-1} = \mathbf{L}^\top \mathbf{D} \mathbf{L}$.

Prior. Se dispone de M estados de la climatología del modelo (anomalías $\mathbf{A}$). La misma regresión sobre ellos da coeficientes climatológicos $\boldsymbol{\beta}_c$, y la incertidumbre a priori sobre $\boldsymbol{\beta}$ se modela como

$$\boldsymbol{\beta} \sim \mathcal{N}(\boldsymbol{\beta}_c, \frac{\sigma^2}{a} \mathbf{I}). \quad (2)$$

Posterior. Con verosimilitud gaussiana el posterior es gaussiano y su media es

$$\widehat{\boldsymbol{\beta}} = \boldsymbol{\beta}_c + (\mathbf{X}^\top \mathbf{X} + a \mathbf{I})^{-1} \mathbf{X}^\top (\mathbf{y} - \mathbf{X} \boldsymbol{\beta}_c) = (\mathbf{X}^\top \mathbf{X} + a \mathbf{I})^{-1} (\mathbf{X}^\top \mathbf{y} + a \boldsymbol{\beta}_c), \quad (3)$$

que es el ridge *hacia* $\boldsymbol{\beta}_c$. Con $\boldsymbol{\beta}_c = 0$ se recupera el ridge ordinario. El parámetro a es la precisión relativa del prior respecto del ruido; se escribe en forma adimensional como

$$a = \alpha \frac{\text{tr}(\mathbf{X}^\top \mathbf{X})}{p}, \quad (4)$$

de modo que α tiene el mismo significado en toda fila y en todo ciclo.

Lo medido. En el primer análisis (ensamble climatológico, $N = 40$), con la estructura de predecesores leída del clima por lasso, el ridge hacia $\boldsymbol{\beta}_c$ da un error 6–9% menor que el mejor radio uniforme, y mejora monótonamente al crecer α hasta 10. En el ciclado convergido, cualquier α grande estorba: el error de fondo deja de parecerse al clima y el prior sesga. Por eso α no puede ser una constante: hay que calibrarla con lo que el filtro tiene a mano en cada ciclo.

2 Tres maneras de calibrar α

2.1 Validación cruzada (lo que no funciona)

Elegir a minimizando el error de predicción dejando un miembro fuera tiene forma cerrada: con $\mathbf{r} = \mathbf{y} - \mathbf{X} \boldsymbol{\beta}_c$ y $\mathbf{X} = \mathbf{U} \mathbf{S} \mathbf{V}^\top$,

$$\text{LOO}(a) = \frac{1}{N} \sum_{k=1}^N \left(\frac{r_k - \hat{r}_k(a)}{1 - h_{kk}(a)} \right)^2, \quad h_{kk}(a) = \sum_j U_{kj}^2 \frac{s_j^2}{s_j^2 + a}. \quad (5)$$

Medido: elige $\alpha = 3$ en el primer ciclo (correcto) y $\alpha = 0.1$ después, y el filtro diverge. La razón: el a óptimo para *predecir anomalías* subestima el a óptimo para la *precisión*. Un β que ajusta bien el ensamble da σ^2 pequeño, $\mathbf{D}_{ii}$ grande, $\hat{\mathbf{B}}^{-1}$ sobreconfiada, y el análisis deja de escuchar a las observaciones: el spread se colapsa. El criterio de predicción no ve ese daño. Queda descartado.

2.2 Verosimilitud marginal (bayes empírico)

Integrando β en (1)–(2), la verosimilitud marginal de la fila es

$$p(\mathbf{y} \mid a, \sigma^2) = \mathcal{N}\left(\mathbf{y}; \mathbf{X}\beta_c, \sigma^2(\mathbf{I} + \frac{1}{a}\mathbf{X}\mathbf{X}^\top)\right), \quad (6)$$

y con la SVD de $\mathbf{X}$ su logaritmo es

$$\log p(\mathbf{y} \mid a, \sigma^2) = -\frac{N}{2} \log \sigma^2 - \frac{1}{2} \sum_{j=1}^p \log \left(1 + \frac{s_j^2}{a}\right) - \frac{1}{2\sigma^2} \left[\|\mathbf{r}\|^2 - \sum_{j=1}^p \frac{s_j^2}{s_j^2 + a} (\mathbf{u}_j^\top \mathbf{r})^2 \right] + \text{cte.} \quad (7)$$

Maximizar (7) en (a, σ^2) es el bayes empírico de tipo II. Tiene un punto fijo cerrado (MacKay):

$$\gamma(a) = \sum_j \frac{s_j^2}{s_j^2 + a}, \quad a \leftarrow \frac{\gamma(a) \sigma^2}{\|\hat{\beta} - \beta_c\|^2}, \quad \sigma^2 \leftarrow \frac{\|\mathbf{y} - \mathbf{X}\hat{\beta}\|^2}{N - \gamma(a)}, \quad (8)$$

donde γ es el número efectivo de coeficientes que los datos determinan. La interpretación es la que buscamos: a es grande cuando $\hat{\beta}$ no se aparta de β_c (el ensamble no contradice el clima), y pequeño cuando sí. A diferencia de la validación cruzada, la evidencia penaliza la complejidad ($\log(1 + s_j^2/a)$) y no premia ajustar ruido. Es la calibración natural y no la hemos probado.

2.3 Consistencia con la dispersión del ensamble (lo que el filtro ve)

El daño de un α mal calibrado se manifiesta en una sola cantidad: la relación entre la dispersión del ensamble y el error. La precisión $\hat{\mathbf{B}}^{-1}(\alpha)$ implica una varianza de fondo; el ensamble tiene la suya; y las innovaciones $\mathbf{d} = \mathbf{y}_{\text{obs}} - \mathbf{H}\mathbf{x}^b$ tienen una covarianza esperada

$$\mathbb{E}[\mathbf{d}\mathbf{d}^\top] = \mathbf{H}\mathbf{B}\mathbf{H}^\top + \mathbf{R}. \quad (9)$$

Con $\mathbf{B}(\alpha) = \hat{\mathbf{B}}^{-1}(\alpha)^{-1}$, se elige el α para el que $\text{tr}(\mathbf{H}\mathbf{B}(\alpha)\mathbf{H}^\top)$ iguala a $\|\mathbf{d}\|^2 - \text{tr}(\mathbf{R})$, o su versión por sitios (Desroziers). Esto calibra α con datos que el filtro sí tiene, y apunta directamente al defecto que la validación cruzada no veía: si $\hat{\mathbf{B}}^{-1}$ es sobreconfiada, $\text{tr}(\mathbf{H}\mathbf{B}\mathbf{H}^\top)$ sale menor que lo que las innovaciones dicen, y α sube. Cuesta una solución rala por valor de α probado (o una estimación estocástica de la traza), y es global, no por fila; se puede usar como α común y dejar que (8) distribuya por fila alrededor de él.

3 Extensión secuencial

El posterior de un ciclo es el prior del siguiente. Con estadísticos suficientes en escala de correlación (para que ciclos con distinto spread pesen igual),

$$\mathbf{G}_t = \rho \mathbf{G}_{t-1} + \frac{1}{N} \mathbf{X}_t^\top \mathbf{X}_t, \quad \mathbf{b}_t = \rho \mathbf{b}_{t-1} + \frac{1}{N} \mathbf{X}_t^\top \mathbf{y}_t, \quad \hat{\beta}_t = (\mathbf{G}_t + a\mathbf{I})^{-1} \mathbf{b}_t, \quad (10)$$

con $\mathbf{G}_0, \mathbf{b}_0$ del clima y $\rho \in [0, 1]$ el olvido. Medido: $\rho = 0.8$ retrasa durante la convergencia (el error cambia más rápido que la memoria) y estorba; $\rho = 0.4$ iguala al uniforme con spread algo menor. La memoria compra N efectivo y sirve cuando la estructura es estacionaria; el mismo criterio de consistencia de §2.3 sirve para elegir ρ : la memoria correcta es la que deja las innovaciones consistentes.

4 Qué se prueba primero

1. α por bayes empírico (8), por fila, con β_c del clima: primer análisis y ciclado en la retícula ($N = 40$, 36 ciclos, contra 0.11 del uniforme).
2. Si sobreajusta como la validación cruzada, α global por consistencia de innovaciones (9) en una malla de valores, y (8) solo para repartir entre filas.
3. Con el α que salga, la memoria ρ en estado estacionario, con la inflación reajustada un punto.

Todo lo anterior son 200 segundos por corrida en la infraestructura actual.